


Rapport d'évaluation du modèle d'analyse de sentiments


Ce rapport présente les performances du prototype développé pour SocialMetrics AI. Le système repose sur deux régressions logistiques entraînées sur les tweets annotés de la table tweets : un modèle prédit si un tweet est positif, l'autre s'il est négatif. Le jeu de données contient 100 tweets annotés. L'évaluation est faite sur 25 pour cent des données, mises de côté pendant l'entraînement.

1. Matrice de confusion des prédictions positives



Sur les 25 tweets de test, le modèle positif classe correctement 15 tweets non positifs et 5 tweets positifs. Il ne produit aucune fausse alerte (0 faux positif), mais il manque 5 tweets réellement positifs, qu'il classe à tort comme non positifs.

2. Matrice de confusion des prédictions négatives



Le modèle négatif classe correctement 15 tweets non négatifs et 7 tweets négatifs. Il produit 0 fausse alerte et manque 3 tweets réellement négatifs. Ce modèle est légèrement plus performant que le modèle positif.

3. Précision, rappel et F1-score

Modèle	Accuracy	Précision	Rappel	F1-score
Positif	0.8	1.0	0.5	0.67
Négatif	0.88	1.0	0.7	0.82

La précision de 1.00 signifie que lorsqu'un modèle signale un sentiment, il ne se trompe presque jamais. En revanche, le rappel plus faible (0.50 pour le positif, 0.70 pour le négatif) montre que les modèles laissent passer une partie des tweets qu'ils devraient détecter. Les modèles sont donc prudents : ils préfèrent ne rien signaler plutôt que de se tromper.

4. Analyse des performances et biais observés

Forces : l'API répond correctement sur des exemples clairs. Un tweet très positif obtient un score proche de 1, un tweet très négatif un score proche de -1 et un tweet neutre un score proche de 0. Aucune fausse alerte n'est produite sur le jeu de test.

Faiblesses : le jeu de données est très petit (une centaine de tweets), donc le vocabulaire connu du modèle est limité. Un tweet exprimé avec des mots absents du jeu d'entraînement obtient un score proche de 0 même s'il est très marqué. Le rappel reste faible, une partie des sentiments n'est pas détectée.

Biais observés : le modèle s'appuie sur des mots isolés (sac de mots). Il ne comprend ni la négation (« pas génial » contient le mot génial et peut être vu comme positif), ni l'ironie, ni le contexte. Les tweets annotés sont synthétiques et bien écrits, alors que les vrais tweets contiennent des fautes, des abréviations et des emojis que le modèle ne connaît pas.

5. Recommandations

1. Agrandir fortement le jeu de données avec de vrais tweets annotés par l'équipe de modération, en visant plusieurs milliers d'exemples.
2. Passer du comptage de mots à une pondération TF-IDF et ajouter des bigrammes pour capturer des expressions comme « pas génial ».
3. Gérer les emojis et les fautes d'orthographe courantes dans le nettoyage des textes.
4. Suivre les performances après chaque réentraînement hebdomadaire pour vérifier que le modèle s'améliore avec les nouvelles données.
5. À plus long terme, tester un modèle de langue pré-entraîné en français, plus robuste que le sac de mots.